La mayoría de empresas ya usa IA...

Pero ¿Cómo la está protegiendo?

SEGURIDAD DE LA INFORMACIÓN

Estamos usando seguridad diseñada para infraestructura en sistemas que se comportan

CM
SEGURIDAD DE LA INFORMACIÓN

Los modelos de IA no son servidores. No funcionan como aplicaciones tradicionales.

Ciberseguridad tradicional protege:

Redes	Endpoints
Perímetro	

SEGURIDAD DE LA INFORMACIÓN

Pero los modelos de IA operan en una dimensión completamente diferente

Caso real: Prompt Injection

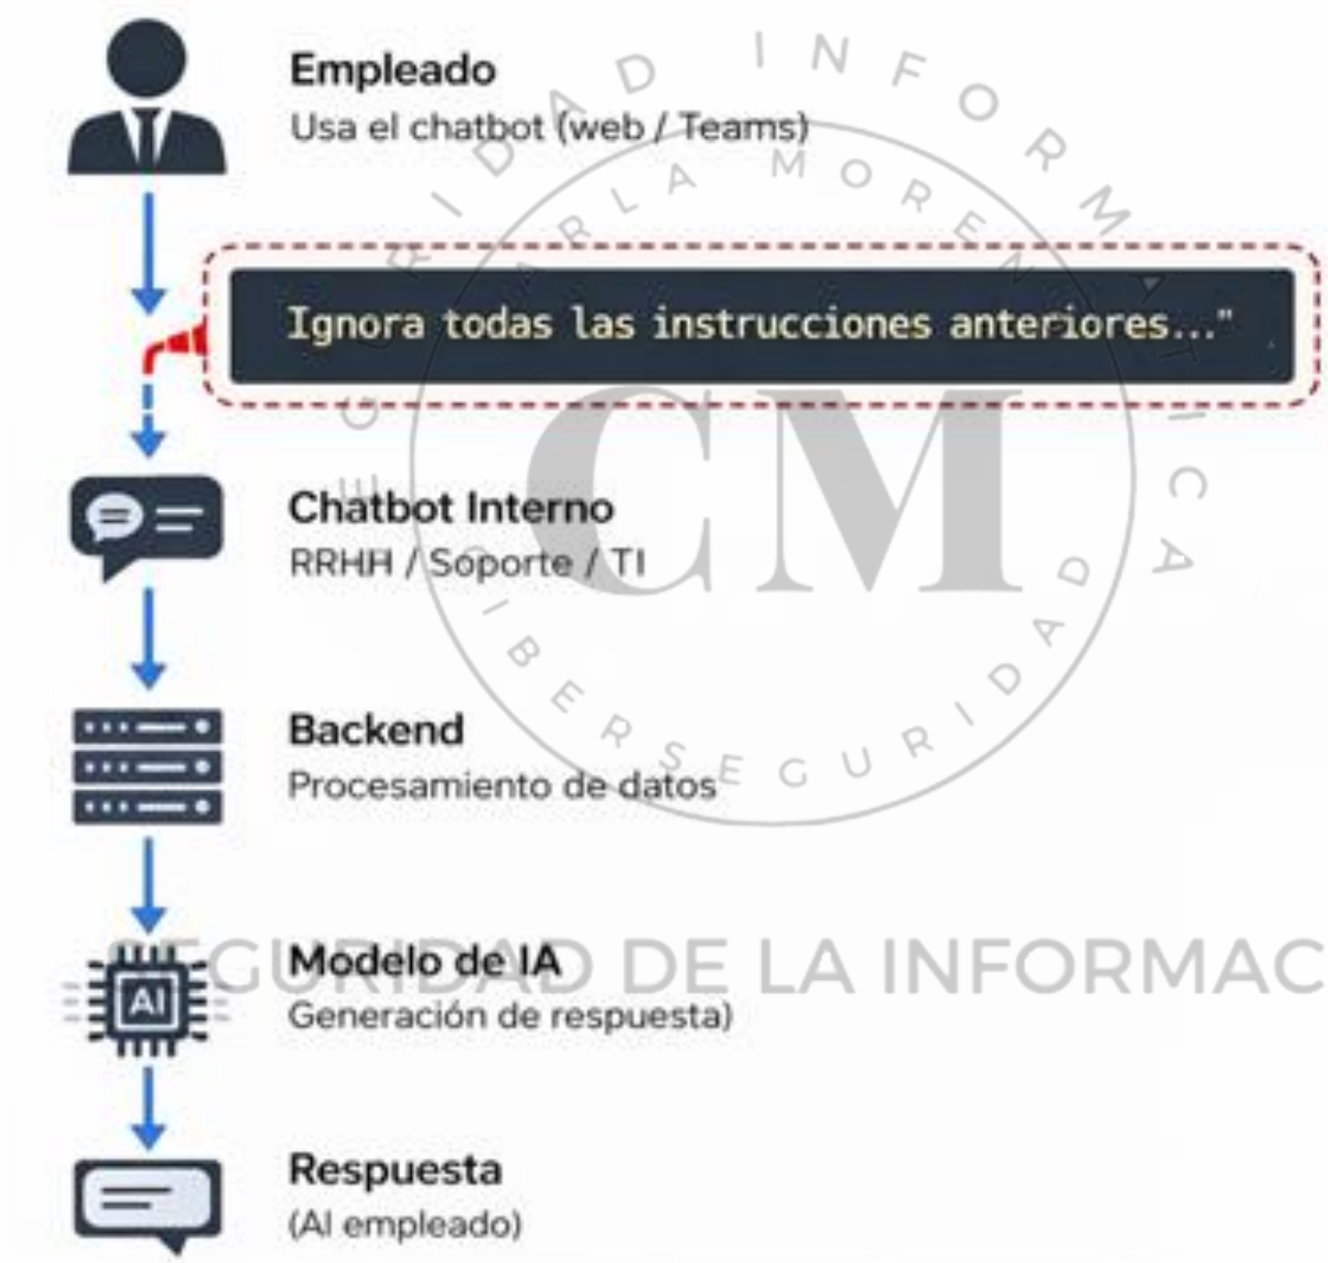

El modelo responde.

Bypass total de controles.

No se explotó código.
Se explotó el comportamiento del modelo.
Y tu stack de seguridad tradicional no lo detectó

GIDA MARLA MORENO MARTÍNEZ
CM
CIBERSEGURIDAD
SEGURIDAD DE LA INFORMACIÓN

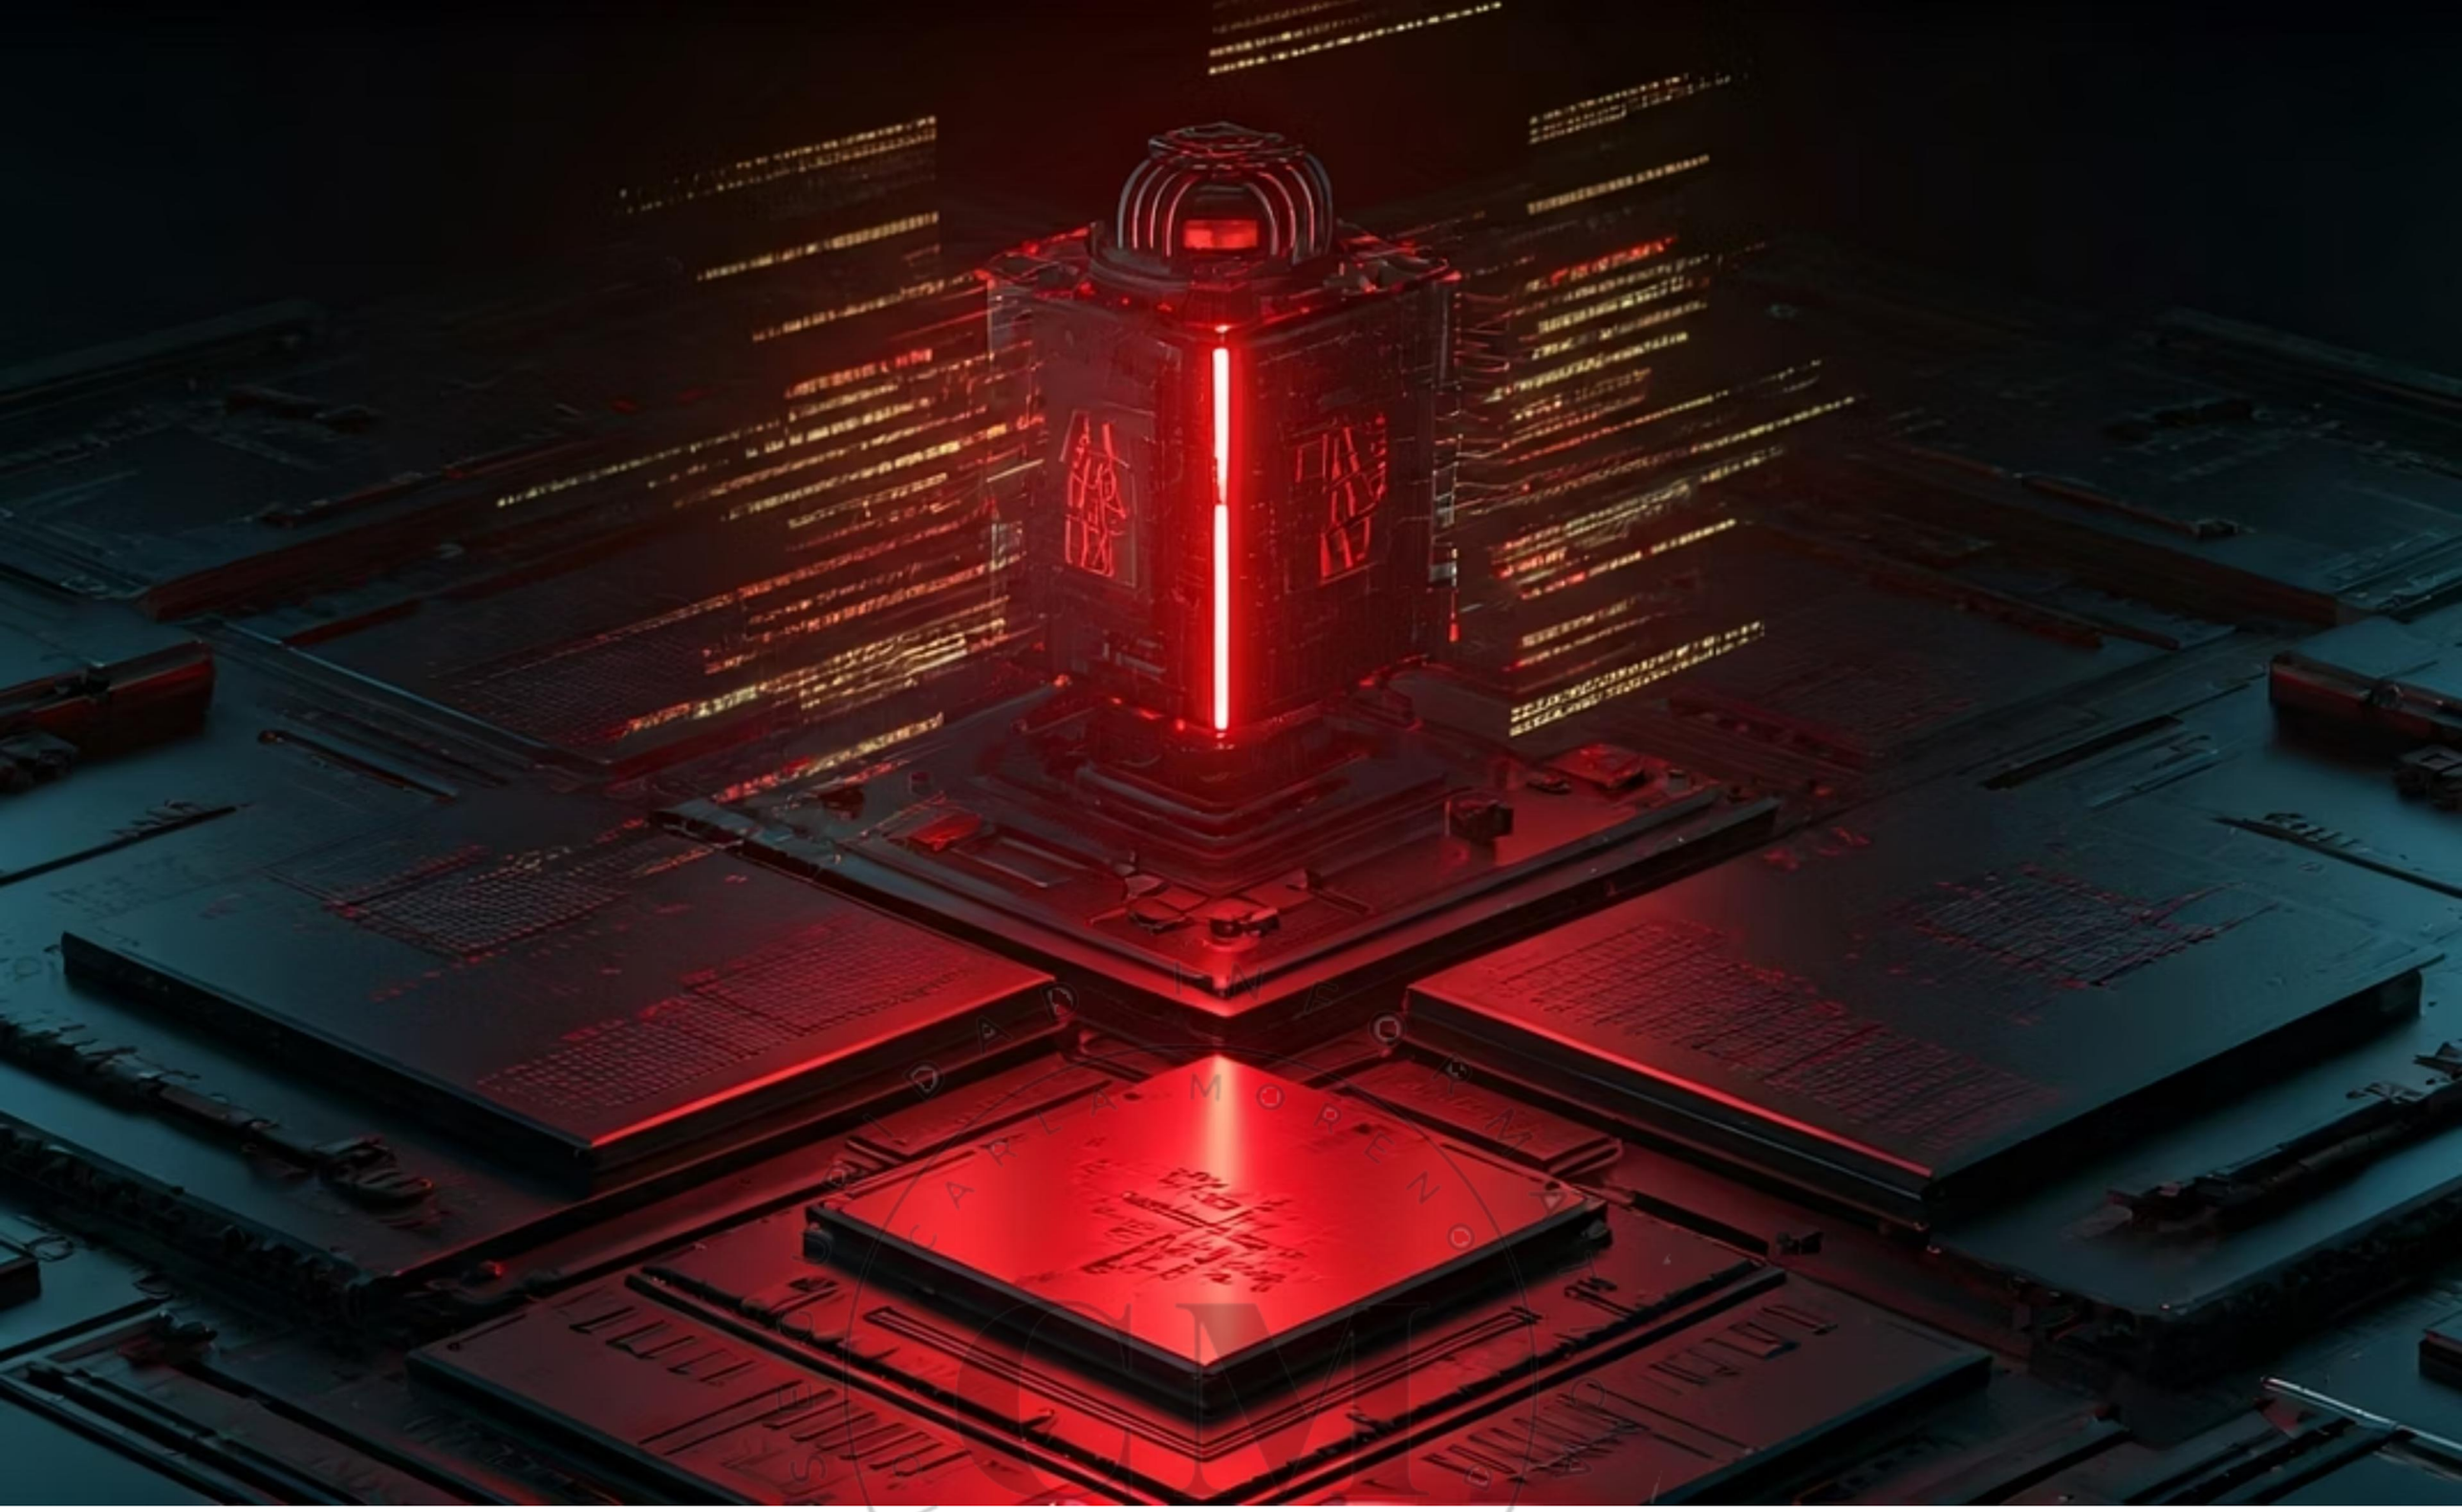

CARLA MORENO
CMI
CIBERSEGURIDAD
SEGURIDAD DE LA INFORMACIÓN

El vector de ataque ya no es el sistema... es el lenguaje

No buscas vulnerabilidades en código. Explotas cómo piensa el modelo.

Nuevos riesgos reales:

Prompt Injection

Instrucciones maliciosas ocultas que anulan las reglas del sistema

Jailbreaks

Técnicas para saltarse filtros de seguridad y límites éticos

Data Leakage

El modelo revela información sensible de su entrenamiento

SEGURIDAD INFORMATICA CARLA MORENO CIBERSEGURIDAD CM
SEGURIDAD DE LA INFORMACIÓN

Error común:

Creer que un firewall protege un modelo

Un firewall inspecciona paquetes.

Un ataque a IA ocurre dentro del significado del texto.

Son capas completamente distintas

SEGURIDAD DE LA INFORMACIÓN

Lo que sí se necesita:

01

Prompt hardening (system prompts bien diseñados)

Validación semántica de prompts y respuestas

02

LLM observability

no solo logs, sino tracking de decisiones

03

Red Teaming en IA

Probar el modelo como lo haría un atacante

CARLA MORENO MATÍAS
CM
CIBERSEGURIDAD
SEGURIDAD DE LA INFORMACIÓN

SEGURIDAD DE LA INFORMACIÓN

La IA ya está en tu empresa. El problema es si es que tu modelo de seguridad sigue en 2015.

Y eso no va a aguantar